

PRINCIPAL COMPONENT ANALYSIS

- $A = U \Lambda U^T$ diagonalizzazione
 - e le colonne $U^{(k)}$ sono gli autovettori
 - e i valori in Λ sono gli autovariori
- Se U è ortogonale ($U^T U = I$)
otteniamo ~~ortogonal~~ autovettori
ortogonali (e possiamo normalizzarli)
- Se $B = P C P^{-1}$ allora B è e
sono simili (se P è ortogonale
allora $P^{-1} = P^T$) quindi anche C è
 Λ sono simili se U è ortogonale

► STEP DELLA PCA

2) CENTRARE IL DATASET dato $x' \in \mathbb{R}^{n \times p}$

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i = \left[\frac{1}{n} \sum_{i=1}^m x_{i1}, \dots, \frac{1}{n} \sum_{i=1}^m x_{ip} \right]$$

$$\hookrightarrow x = \begin{bmatrix} x_1' - \mu \\ \vdots \\ x_n' - \mu \end{bmatrix} \quad \begin{array}{l} \text{le features} \\ \rightarrow \text{vengono centrate} \end{array}$$

> OBIETTIVO

Vogliamo ottenere una trasformazione

$$\text{NUOVO} \rightarrow T = Xw$$

↑
DATASET

↑
DATASET

Dove w è una matrice in cui ogni colonna è una "direzione" principale dei dati \rightarrow

$$w^{(1)} = \underset{w \in \mathbb{R}^P}{\text{argmax}} \left\{ \frac{1}{m-1} \sum_{i=1}^m \left(\sum_{j=1}^P x_{ij} w_j \right)^2 \right\}$$

$$\text{con } \|w\|_2 = 1$$

$$x_i \cdot w \quad \xrightarrow{\text{signo}} \quad \begin{cases} + & x_i \cdot w > 0 \\ - & x_i \cdot w < 0 \end{cases}$$

$$= \underset{w \in \mathbb{R}^P}{\text{argmax}} \|Xw\|^2 = \underset{w \in \mathbb{R}^P}{\text{argmax}} X^T w + Xw$$

$$\text{con } \|w\|_2 = 1$$

$$\text{con } \|w\|_2 = 1$$

$$= \underset{w \in \mathbb{R}^P}{\text{argmax}} \frac{w^T X^T X w}{w^T w} = \text{Autovettore con } P' \text{ autovalue più grande di } X^T X$$

Ogniodi sottraendo la direzione w si rimpicciolisce una certa porzione delle varianze.

Togliamo quest'ultima per rimanere con la varianza rimasta:

$$x_k = x - x \sum_{i=1}^{k-1} w^{(i)} (w^{(i)})^T$$

proiezione di x sulle direzioni trovate

Dove k è il numero di dimensioni trovate

x_k è la proiezione dei dati

~~trovate~~ sullo spazio perpendicolare alle direzioni trovate

Se ripetiamo la stessa procedura

su x_1 otteniamo $w^{(2)}$, se ripetiamo su x_2 otteniamo $w^{(3)}$, ecc...

INTERPRETAZIONE,

Possiamo col colore la matrice di covarianza del dataset come:

$$C = \frac{1}{n-1} \sum_{i=1}^n x_i^T x_i = \frac{1}{n-1} X^T X$$

1) Dal teorema spettrale $Au^{(1)} = \lambda_1 u^{(1)}$

$$X^T X w^{(1)} = \lambda_1 w^{(1)}$$

$$(w^{(1)})^T X^T X w^{(1)} = \lambda_1 w^{(1)} \cdot (w^{(1)})^T$$

$$(w^{(1)})^T X^T X w^{(1)} = \lambda_1 \underbrace{\|w^{(1)}\|^2}_{\|X w^{(1)}\|^2} \quad \|w^{(1)}\| = 1$$

$$\|X w^{(1)}\|^2 = \lambda_1$$

2) Dai ragionamenti precedenti;

$$\text{Var}(X w^{(1)}) = \frac{1}{n-1} \|X w^{(1)}\|^2 = \frac{\lambda_1}{n-1}$$

Se facciamo la trasformazione
~~con~~ con la w ottenuta

$$T = X w$$

Ottieniamo la nuova rappresentazione del dataset. Calcoliamo la matrice di covarianza

$$C' = \frac{\mathbf{I}^T \mathbf{I}}{n-1} = \frac{\mathbf{W}^T \mathbf{X}^T \mathbf{X} \mathbf{W}}{n-1} = \begin{matrix} \text{autocor.} \\ \text{autocor.} \end{matrix}$$

per il teorema spettrale $\mathbf{A} = \mathbf{U} \Lambda \mathbf{U}^T$

$$= \frac{\mathbf{W}^T \mathbf{W} \Lambda \mathbf{W}^T \mathbf{W}}{n-1} = \frac{\Lambda}{n-1} = \begin{pmatrix} \text{Var}_1 & 0 & 0 \\ 0 & \text{Var}_2 & 0 \\ \vdots & \ddots & \text{Var}_p \end{pmatrix}$$

Quindi nella nuova rappresentazione le features sono indipendenti!

RIDUZIONE DELLA DIMENSIONALITÀ

Possiamo scegliere solo alcune delle "dimensioni principali" e spiegare solo una percentuale della varianza, ad esempio solo il 95%



Per scegliere usiamo un indice
chiamato proporzionalità di varianza
spiegata

$$PVG = \frac{\sum_{k=1}^m \left[\sum_{i=1}^n \frac{1}{m-1} \sum_{j=1}^p x_{ij} w_{ik} \right]}{\sum_{j=1}^p \frac{1}{m-1} \sum_{i=1}^n x_{ij}^2}$$
$$\leq \frac{\sum_{k=1}^m \lambda_k}{\sum_{j=1}^p \lambda_j}$$

N.B.: il numero di autovetori che
possiamo scegliere come gli m
principali dipendono del
range di $X^T X$

$$m \leq \text{range}[X^T X]$$

SINGULAR VALUE DECOMPOSITION

Usare la diagonalizzazione per trovare gli autovalori funzione
solo se la matrice
è quadrata $\rightarrow A = U \Sigma V^T$

Se invece è rettangolare abbiamo che

$$M_{m \times p} = U_{m \times m} \cdot \Sigma_{m \times p} \cdot V^T_{p \times p}$$

sono
matrici
ortogonali

oppure, se $\text{range}[M] < \min\{m, p\}$

$$M_{m \times p} = U_{m \times n} \cdot \Sigma_{n \times n} \cdot V^T_{n \times p}$$

Quindi $M = U \Sigma V^T$

Usiamo questa proprietà su $x^T x$

$$x^T x = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T$$

Da cui possiamo dire che

$x^T x$ e $\Sigma^T \Sigma$ sono simili, cioè
hanno gli stessi autovalori

Sappiamo però che gli autovalori

gli $X^T X$ sono proporzionali alla varianza di ogni feature e quindi gli autovettori associati sono le direzioni principali, lo stesso però possiamo dire di V !

Quindi

$$T = X V$$

Usando la su> possiamo anche riscrivere

$$T = X V = U \Sigma V^T V = U \Sigma$$

Quindi possiamo ottenere il nuovo dataset da entrambi i singolar vectors (U e V)